

Voici comment fonctionne un **Bigram Model**, étape par étape, avec un exemple concret pour illustrer le processus.

1. Collecte des données

On part d'un (un texte de référence). Exemple : *"Je une pomme. Je bois de l'eau."*

2. Tokenisation

On découpe le texte en mots (tokens) et on ajoute des symboles spéciaux pour marquer le début (<s>) et la fin (</s>) des phrases.

Phrases tokenisées :

1. <s> Je mange une pomme . </s>
2. <s> Je bois de l eau . </s>

3. des bigrammes

On extrait toutes les paires de mots consécutifs.

Bigrammes de la 1ère phrase :

- <s> Je
- Je mange
- mange une
- une pomme
- pomme .
- . </s>

Bigrammes de la 2ème phrase :

- <s> Je
- Je bois
- bois de
- de l
- l eau
- eau .
- . </s>

4. Calcul des fréquences

On compte combien de fois chaque bigramme apparaît, ainsi que la fréquence de chaque mot individuel.

Bigramme	Fréquence
Je	2
Je mange	1
Je bois	1
mange une	1
une pomme	1
pomme .	1
.	2
bois de	1
de l	1
l eau	1
eau .	1

Mot	Fréquence
	2
Je	2
mange	1
une	1
pomme	1
.	2
bois	1
de	1
l	1
eau	1
	2

5. Calcul des probabilités

On calcule la probabilité d'un mot **B** sachant le mot précédent **A** :

$P(B | A) = \frac{\text{Fréquence du bigramme } (A, B)}{\text{Fréquence du mot } A}$
 $P(B | A) = \frac{\text{Fréquence du bigramme } (A, B)}{\text{Fréquence du mot } A}$

Exemples :

- $P(\text{mange} | \text{Je}) = \frac{1}{2} = 0.5$ (car "Je" apparaît 2 fois, et "mange" apparaît 1 fois)
- $P(\text{bois} | \text{Je}) = \frac{1}{2} = 0.5$
- $P(\text{une} | \text{mange}) = \frac{1}{1} = 1.0$
- $P(\text{pomme} | \text{une}) = \frac{1}{1} = 1.0$

6. Génération de texte

Pour générer une phrase, on commence par <s> et on choisit le mot suivant en fonction des probabilités.

Exemple :

1. On commence par <s>.
2. Le seul bigramme commençant par <s> est <s> Je → on choisit "**Je**".
3. Après "Je", les options sont :
 - "mange" (probabilité = 0.5)
 - "bois" (probabilité = 0.5) On tire au hasard (ou on choisit la plus probable) → supposons qu'on choisit "**mange**".
4. Après "mange", le seul bigramme est mange une → on choisit "**une**".
5. Après "une", le seul bigramme est une pomme → on choisit "**pomme**".
6. Après "pomme", le seul bigramme est pomme . → on choisit ".".
7. Après ".", le seul bigramme est . </s> → on choisit "</s>" (fin de phrase).

Résultat généré : <s> Je mange une pomme . </s>

7. Lissage (Smoothing)

Problème : Si un bigramme n'apparaît **jamais** dans le , sa probabilité est **0**, ce qui bloque la génération. Solution : On utilise des techniques comme **Laplace Smoothing** (ajouter 1 à toutes les fréquences) pour éviter les probabilités nulles.

Résumé en une phrase

Un **Bigram Model** prédit le mot suivant en fonction du mot précédent, en utilisant les fréquences observées dans un .

Tu veux que je t'explique comment l'implémenter en , ou tu as d'autres questions ?

pour le trigramme il a le meme principe on change juste au lieu de 2mots en prend 3 mots